Problem Set 01 — Các câu hỏi và Dữ liệu

UET.MAT1052 — Xác suất thống kê

Hoàng Thị Điệp, Nghiêm Nguyễn Việt Dũng, Lê Thị Hường

Mục tiêu

Problem Set 01 luyện chuỗi tư duy của Tuần 01:

câu hỏi → đơn vị + biến → quá trình tạo dữ liệu → khung dữ liệu và mức chi tiết của hàng → phân tích → khẳng định hợp lệ.

Sau khi hoàn thành problem set, sinh viên cần có khả năng:

1. thực hiện bằng tay các phép biến đổi số học nhỏ để nhìn rõ **mẫu số, trọng số, phép gộp và phép đo lặp**;
2. phân biệt **tóm tắt, tổng quát hóa, dự đoán và khẳng định nhân quả**, đồng thời nhận ra khi dữ liệu chỉ hỗ trợ một **mối liên hệ**;
3. đi ngược từ một khẳng định để hỏi dữ liệu đã được **tạo ra/thu thập** như thế nào;
4. xác định **đơn vị quan sát, biến, giá trị, loại biến và mức chi tiết của mỗi hàng**;
5. nhận ra **số hàng không đồng nhất với số đơn vị độc lập** trong mọi bài toán;
6. đọc cấu trúc cơ bản của một `DataFrame` và phân biệt **loại biến thống kê** với `dtype` của phần mềm.

Yêu cầu chung

- Trả lời bằng **lập luận**, không chỉ ghi một nhãn như "tóm tắt", "nhân quả", "biến phân loại", ...
- Nếu cho rằng dữ liệu **không đủ** để hỗ trợ một khẳng định, phải chỉ rõ bước suy luận nào vượt quá dữ liệu hoặc quá trình tạo dữ liệu còn thiếu điều gì.
- Khi gặp dữ liệu có nhiều hàng, phải hỏi: **mỗi hàng là gì, đơn vị nào được đo lặp, và câu hỏi đang đếm loại đơn vị nào?**
- Với bài Python ở Phần C, chỉ cần các thao tác đọc cấu trúc đã học ở Week 01: `head()`, `shape`, `columns`, `dtypes`.
- Không yêu cầu kiến thức về xác suất hay suy luận thống kê ngoài phạm vi Tuần 01.

Phần A — Tính tay

Bài 1 — Từ số đếm đến tỷ lệ: mẫu số làm thay đổi câu chuyện

Một trung tâm dữ liệu sử dụng hai loại máy chủ. Trong một tháng:

Loại máy chủ	Số máy đang vận hành	Số máy gặp sự cố
A	2.400	48
B	700	21

Không dùng Python. Hãy ghi đầy đủ các bước tính.

1. Nếu chỉ nhìn vào **số sự cố**, loại nào có nhiều sự cố hơn?
2. Tính tỷ lệ máy gặp sự cố của từng loại dưới dạng:
   - phân số;
   - phần trăm;
   - số sự cố trên 1.000 máy.
3. Sau khi dùng mẫu số thích hợp, loại nào có **tỷ lệ** sự cố cao hơn?
4. Giải thích bằng một câu vì sao so sánh `48` với `21` trả lời một câu hỏi khác với so sánh hai tỷ lệ vừa tính.
5. Viết một **câu tóm tắt** được dữ liệu hỗ trợ trực tiếp.
6. Một kỹ sư nói: "Dùng loại B **làm tăng** nguy cơ sự cố." Câu này đi xa hơn phép tính ở trên như thế nào?

Bài 2 — Tốt hơn trong từng nhóm, tệ hơn khi gộp

Hai hệ thống A và B được dùng để xử lý hai loại tác vụ: **dễ** và **khó**. Kết quả:

Loại tác vụ	Hệ thống A	Hệ thống B
Dễ	9 thành công / 10	80 thành công / 100
Khó	20 thành công / 100	1 thành công / 10

Không dùng Python.

1. Tính tỷ lệ thành công của A và B **trong nhóm tác vụ dễ**.
2. Tính tỷ lệ thành công của A và B **trong nhóm tác vụ khó**.
3. Trong từng nhóm, hệ thống nào có tỷ lệ thành công cao hơn?

4. Gộp hai loại tác vụ lại. Tính:

   - tổng số tác vụ và tổng số thành công của A;
   - tổng số tác vụ và tổng số thành công của B;
   - tỷ lệ thành công chung của mỗi hệ thống.

5. Sau khi gộp, hệ thống nào có tỷ lệ cao hơn? Kết luận có cùng chiều với câu 3 không?

6. Điền hai câu sau bằng số cụ thể:

   "Trong từng loại tác vụ, _____ tốt hơn _____."
   "Khi gộp toàn bộ tác vụ, _____ lại có tỷ lệ thành công cao hơn _____."

7. Giải thích **bằng mẫu số và trọng số của hai loại tác vụ** vì sao có thể xảy ra hiện tượng đảo chiều này.

8. Nếu bảng ban đầu có một hàng cho mỗi `hệ thống × loại tác vụ`, còn bảng gộp chỉ có một hàng cho mỗi hệ thống, thông tin nào đã bị mất?

Bài 3 — Một trung bình hay hai trung bình? Phép đo lặp và trọng số

Ba bộ pin được đo nhiệt độ trong một thử nghiệm. Do mất dữ liệu, số phép đo còn lại không bằng nhau:

Bộ pin	Các nhiệt độ còn lại (°C)
P1	10, 14
P2	20, 20, 20, 20
P3	30

Không dùng Python.

1. Có bao nhiêu **bộ pin**? Có bao nhiêu **hàng/phép đo** nếu mỗi giá trị nhiệt độ được lưu thành một hàng?

2. Tính nhiệt độ trung bình riêng của P1, P2 và P3.

3. Tính **trung bình của ba trung bình theo pin**:

$$\frac{\bar{x}_{P1} + \bar{x}_{P2} + \bar{x}_{P3}}{3}$$

4. Bây giờ bỏ qua ranh giới giữa các pin và tính **trung bình của toàn bộ 7 phép đo gốc**.

5. Hai kết quả ở câu 3 và 4 có bằng nhau không?

6. Trong câu 3, đơn vị nào được cho trọng số bằng nhau: **pin** hay **phép đo**? Trong câu 4 thì sao?
7. Vì sao "7 hàng dữ liệu" không đồng nghĩa với "7 bộ pin độc lập"?
8. Nếu câu hỏi nghiên cứu là "nhiệt độ điển hình của **một bộ pin**", bạn thấy phép tính nào gần với câu hỏi hơn? Nếu câu hỏi là "nhiệt độ điển hình của **một phép đo được ghi lại**", câu trả lời có thể thay đổi thế nào?

Bài 4 — Từ dữ liệu từng sinh viên đến bảng liên hợp bằng tay

Một khảo sát nhỏ có 10 sinh viên. Mỗi hàng là một người trả lời:

`student_id`	`season`	`mts_beach`	`coding_exp`
01	Spring	Beach	No
02	Spring	Mountains	Yes
03	Summer	Beach	No
04	Summer	Beach	Yes
05	Summer	Mountains	No
06	Fall	Mountains	Yes
07	Fall	Mountains	No
08	Winter	Beach	Yes
09	Winter	Mountains	No
10	Winter	Beach	No

Không dùng Python.

1. Đơn vị quan sát của bảng gốc là gì? Bảng có bao nhiêu observations?
2. Tự lập bằng tay bảng đếm `season × mts_beach` sau, điền tất cả các ô và tổng hàng/cột:

`season`	Mountains	Beach	Total
Spring			
Summer			
Fall			
Winter			
Total			**10**

3. Với mỗi mùa, tính **tỷ lệ trong hàng** chọn `Beach`.
4. Sau khi chỉ giữ bảng liên hợp ở câu 2, ta còn biết sinh viên `04` có `coding_exp = Yes` hay không?
5. Có thể khôi phục **duy nhất** thứ tự 10 sinh viên ban đầu từ bảng đếm không? Vì sao?

6. So sánh mức chi tiết:
    - bảng gốc: một hàng = ?
    - bảng tổng hợp: một ô = ?
7. Viết một câu giải thích tại sao **gộp dữ liệu không chỉ làm bảng ngắn hơn mà còn thay đổi loại câu hỏi còn có thể trả lời**.

Phần B — Freedman

Bài 5 — Người vừa bỏ thuốc có vẻ kém khỏe hơn

Một nghiên cứu **quan sát** so sánh những người đang hút thuốc với những người **gần đây đã bỏ thuốc**. Sau khi xem xét các nhóm tuổi và giới tính, nhóm vừa bỏ thuốc có vẻ có sức khỏe kém hơn.

Một người kết luận:

> "Bỏ thuốc làm sức khỏe xấu đi."

1. Kết quả được mô tả ở trên cho biết điều gì về **mối liên hệ quan sát được** giữa tình trạng hút thuốc và sức khỏe?
2. Câu "Bỏ thuốc làm sức khỏe xấu đi" thuộc loại khẳng định nào trong bốn loại của Week 01?
3. Vì sao bước từ câu 1 sang câu 2 không được bảo đảm chỉ bởi bảng dữ liệu quan sát?
4. Hãy mô tả một **quá trình tạo dữ liệu hợp lý** trong đó sức khỏe kém xuất hiện trước, rồi chính sức khỏe kém làm một số người quyết định bỏ thuốc.
5. Viết lại kết luận thành một câu **yếu hơn nhưng phù hợp với dữ liệu đã mô tả**.
6. Nếu muốn trả lời câu hỏi "điều gì sẽ xảy ra với sức khỏe nếu một người bỏ thuốc thay vì tiếp tục hút?", vì sao chỉ thêm nhiều hàng vào cùng kiểu nghiên cứu quan sát chưa chắc giải quyết được vấn đề?

Bài 6 — "Cha mẹ nên bớt kiểm soát"?

Một nghiên cứu ở trẻ nhỏ ghi nhận rằng những trẻ có nhiều mỡ cơ thể hơn có xu hướng có mẹ được đánh giá là có hành vi **kiểm soát** nhiều hơn. Một bài báo từ đó đưa ra lời khuyên rằng cha mẹ của trẻ thừa cân nên bớt kiểm soát con.

1. Phát hiện của nghiên cứu mô tả điều gì về **hai biến** đang được quan sát?
2. Lời khuyên của bài báo ngầm chứa một **khẳng định nhân quả** nào?

3. Chỉ ra chính xác bước chuyển từ **mối liên hệ quan sát được** sang khẳng định nhân quả.
4. Đưa ra **hai cơ chế tạo dữ liệu khác nhau** cũng có thể tạo ra cùng mối liên hệ quan sát được mà không cần giả định "kiểm soát nhiều → tăng mỡ cơ thể".
5. Viết một tiêu đề/kết luận thay thế **không đi xa hơn dữ liệu**.
6. Nếu nghiên cứu chỉ gồm các gia đình tự nguyện tham gia tại một địa điểm, câu "mọi trẻ em đều có xu hướng như vậy" còn thêm một bước suy luận nào khác ngoài vấn đề nhân quả?

Bài 7 — Boot camp và tái phạm

Một chương trình cải tạo tù nhân cho phép phạm nhân **tự nguyện** tham gia một khóa "boot camp". Sau khi ra tù, những người **hoàn thành** boot camp có tỷ lệ quay lại nhà tù thấp hơn nhóm tù nhân còn lại.

Một phát ngôn viên nói rằng chương trình đã làm giảm tái phạm.

1. Viết một câu **tóm tắt** mà dữ liệu trên trực tiếp hỗ trợ.
2. Phát biểu "boot camp làm giảm tái phạm" thuộc loại khẳng định nào?
3. Vẽ bằng lời chuỗi tạo ra hai nhóm được so sánh: ai có cơ hội tham gia, ai **tự chọn** tham gia, ai **hoàn thành**, và ai nằm trong nhóm còn lại.
4. Hai nhóm có thể đã khác nhau **trước khi chương trình bắt đầu** như thế nào? Nêu ít nhất hai khả năng.
5. Vì sao từ "tự nguyện" và điều kiện "hoàn thành" đặc biệt quan trọng khi đánh giá kết luận?
6. Giả sử thu thập thêm dữ liệu trên 100.000 tù nhân bằng đúng quy trình tự nguyện đó. Số hàng lớn hơn có tự động biến kết luận thành nhân quả không? Giải thích.
7. Viết một kết luận thận trọng hơn mà người phát ngôn viên có thể sử dụng.

Phần C — STAT20

Bài 8 — Cùng được lưu bằng số, nhưng không cùng loại biến

Một hệ thống lưu bốn cột sau:

Cột	Một vài giá trị	Ý nghĩa
`student_id`	24001234, 24001235, 24001236	mã sinh viên

Cột	Một vài giá trị	Ý nghĩa
`satisfaction`	1, 2, 3, 4, 5	từ "rất không hài lòng" đến "rất hài lòng"
`num_siblings`	0, 1, 2, 3, …	số anh/chị/em ruột
`temperature_c`	21.4, 21.9, 22.1, …	nhiệt độ đo bằng °C

Phần mềm có thể lưu ba cột đầu bằng kiểu số nguyên và cột cuối bằng số thực.

1. Phân loại **loại biến thống kê** của từng cột theo hệ thống Week 01.
2. Với cột nào phép toán chênh lệch giữa hai giá trị có ý nghĩa định lượng tự nhiên? Với cột nào các con số chủ yếu là **mã hoặc mức**?
3. Có nên tính trung bình của `student_id` không? Giải thích mà không viện dẫn quy tắc phần mềm.
4. Nếu đổi `satisfaction` thành các nhãn chữ `"very dissatisfied"`, …, `"very satisfied"`, loại biến thống kê có thay đổi không?
5. Nếu `student_id` có `dtype = int64`, điều đó cho biết gì và **không cho biết gì**?
6. Viết một quy tắc một câu giúp phân biệt **statistical variable type** với **software dtype**.

Bài 9 — Palmer Penguins: đọc cấu trúc trước khi phân tích

STAT20 sử dụng bộ dữ liệu **Palmer Penguins** để minh họa observational unit, variable type và data frame.

Dữ liệu mở

Dùng **trực tiếp** bản CSV công khai của dự án Palmer Penguins:

https://raw.githubusercontent.com/allisonhorst/palmerpenguins/main/inst/extdata/penguins.csv

Đọc bằng Python:

```
import pandas as pd

url = "https://raw.githubusercontent.com/allisonhorst/palmerpenguins/main/inst/extdata/pengu
penguins = pd.read_csv(url)

penguins.head()
penguins.shape
penguins.columns
penguins.dtypes
```

Chỉ cần bốn đầu ra trên. Không cần tính thống kê mô tả hay vẽ biểu đồ.

Câu hỏi

1. `penguins.shape` cho biết số hàng và số cột. Vì sao chỉ từ hai con số này ta **chưa biết** mỗi hàng đại diện cho gì?
2. Dựa vào mô tả bộ dữ liệu và các cột, xác định **đơn vị quan sát** của một hàng.
3. Phân loại các biến `species`, `island`, `bill_length_mm`, `body_mass_g`, `year`.
4. So sánh câu trả lời ở mục 3 với `penguins.dtypes`. Chọn **hai cột** minh họa rõ rằng `dtype` và loại biến thống kê trả lời hai câu hỏi khác nhau.
5. Nếu mã hóa `species` bằng `Adelie = 1`, `Chinstrap = 2`, `Gentoo = 3`, cột mới có trở thành biến số rời rạc không? Vì sao?
6. Nếu thay `bill_length_mm` bằng ba mức có thứ tự `short < medium < long`, hãy nêu:
   - loại biến mới;
   - một loại thông tin đã bị mất so với phép đo ban đầu.
7. Từ file CSV một mình, ta có biết đầy đủ **quá trình các chim cánh cụt được chọn và đo** hay không? Nêu ít nhất hai câu hỏi về quá trình tạo dữ liệu mà bạn sẽ muốn biết trước khi tổng quát hóa kết quả ra ngoài các cá thể trong file.

Bài 10 — Quốc gia hay quốc gia–năm? Phép đo lặp nằm ở đâu?

STAT20 dùng ngữ cảnh dữ liệu của Hans Rosling để mô tả sự thay đổi theo thời gian của các quốc gia. Xét bảng thu nhỏ:

country	year	life_expectancy	population	region
Vietnam	2000			Asia
Vietnam	2010			Asia
Japan	2000			Asia
Japan	2010			Asia
Kenya	2000			Africa
Kenya	2010			Africa

Các ô số liệu để trống có chủ ý; bài này hỏi về **cấu trúc**, không hỏi về giá trị cụ thể.

1. Bảng trên có bao nhiêu **hàng/observations trong bảng**? Đơn vị của một hàng chính xác nhất là gì?
2. Có bao nhiêu **quốc gia khác nhau**? Quốc gia nào đang được đo lặp?
3. Vì sao "6 hàng" không đồng nghĩa với "6 quốc gia độc lập"?

4. `country` là đơn vị quan sát hay là một biến trong bảng? Giải thích vì sao hai khái niệm này không đồng nhất.
5. Phân loại `year`, `life_expectancy`, `population`, `region`.
6. Nếu câu hỏi là "quốc gia nào có tuổi thọ cao nhất **năm 2010**?", mức chi tiết `country × year` có đủ không?
7. Nếu câu hỏi đổi thành "quốc gia nào có **tuổi thọ trung bình trong cả giai đoạn** cao nhất?", bạn có thể tạo một bảng một hàng/một quốc gia không? Khi đó thông tin nào bị gộp đi?
8. Nếu câu hỏi là "tuổi thọ thay đổi thế nào **theo thời gian trong cùng một quốc gia**?", vì sao gộp sớm thành một hàng/một quốc gia có thể phá hỏng dữ liệu cần thiết?
9. `region = Asia` lặp lại ở nhiều hàng. Vì sao điều đó không tự động có nghĩa dữ liệu bị duplicate?

Nguồn chính

1. Freedman, D., Pisani, R., & Purves, R. (2007). *Statistics* (4th ed.). W. W. Norton & Company. ISBN 978-0-393-92972-0. https://wwnorton.com/books/9780393929720/about-the-book
2. UC Berkeley STAT20, course materials: https://stat20.berkeley.edu/
3. STAT20 — Taxonomy of Data: https://stat20.berkeley.edu/fall-2024/1-questions-and-data/02-taxonomy-of-data/notes.html
4. Diez, D. M., Çetinkaya-Rundel, M., & Barr, C. D. *OpenIntro Statistics* (4th ed.), Chapter 1. https://www.openintro.org/book/os/
5. Çetinkaya-Rundel, M., & Hardin, J. *Introduction to Modern Statistics* (2nd ed.). https://openintrostat.github.io/ims/index.html
6. Palmer Penguins open data: https://github.com/allisonhorst/palmerpenguins