Bài tập 04 — Tương quan và hồi quy

UET.MAT1052 — Xác suất thống kê

Hoàng Thị Điệp, Nghiêm Nguyễn Việt Dũng, Lê Thị Hường

Chuẩn bị dữ liệu

- Tải tệp CSV từ nguồn chính thức, lưu trong thư mục `data/` và đọc bằng `pandas`.
- Trong bài nộp, đọc dữ liệu từ tệp cục bộ; không dùng URL trong `pd.read_csv()`.

Bài 1

Năm quan sát Adelie dưới đây được lấy từ bộ dữ liệu `penguins` dùng trong STAT20. Hai biến là chiều dài mỏ (`bill_length_mm`) và chiều dài cánh bơi (`flipper_length_mm`).

Chim	x: bill length (mm)	y: flipper length (mm)
1	39.1	181
2	39.5	186
3	40.3	195
4	36.7	193
5	39.3	190

1. Tính $\bar{x}$ và $\bar{y}$.
2. Lập bảng gồm năm cột

$$x_i - \bar{x}, \qquad y_i - \bar{y}, \qquad (x_i - \bar{x})(y_i - \bar{y}), \qquad (x_i - \bar{x})^2, \qquad (y_i - \bar{y})^2.$$

3. Không dùng s_x, s_y, hãy tính trực tiếp

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}.$$

4. Nếu r của 5 quan sát này gần 0, một sinh viên kết luận: "chiều dài mỏ không giúp ta biết gì về chiều dài cánh bơi của chim cánh cụt". Bạn đánh giá thế nào về kết luận này.

Bài 2

Bốn nhà hàng dưới đây là các quan sát trong dữ liệu `zagat` của STAT20. Chỉ dùng hai biến `food` (thang 0–30) và `price` (USD).

Nhà hàng	x: food	y: price
Daniella Ristorante	22	43
Tello's Ristorante	20	32
Pasticcio	20	34
Belluno	22	39

Ta muốn khớp bởi mô hình hồi quy tuyến tính

$$\widehat{price} = b_0 + b_1\, food.$$

1. Tính $\bar{x}, \bar{y}$, rồi tính
$$b_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \qquad b_0 = \bar{y} - b_1 \bar{x}.$$

2. Tính $\hat{y}_i$ và phần dư $e_i = y_i - \hat{y}_i$ cho cả 4 nhà hàng. Kiểm tra bằng tay hai điều kiện
$$\sum e_i = 0, \qquad \sum x_i e_i = 0.$$

3. Tính $SSE = \sum e_i^2$.

4. Zagat đổi thang điểm thức ăn từ 0–30 sang 0–100 bằng
$$x^* = \frac{100}{30} x.$$
Không khớp lại mô hình, hãy viết ngay đường hồi quy theo x^* và cho biết hệ số tương quan Pearson r thay đổi thế nào.

Bài 3

OpenIntro dùng dữ liệu 15 cuốn sách để giải thích `weight` (gram) từ `volume` (cm^3) và loại bìa. Xét hai mô hình đã được khớp trên **toàn bộ 15 cuốn sách**:

$$M_0: \quad \widehat{weight} = 108 + 0.71\, volume,$$

$$M_1: \quad \widehat{weight} = 197.96 + 0.72\, volume - 184.05 I(pb),$$

trong đó $I(pb) = 1$ nếu bìa mềm và bằng 0 nếu bìa cứng.

Dùng bốn cuốn sau để kiểm tra bằng tay:

ID	volume	weight	cover
4	239	350	hb
8	412	250	pb
11	1492	975	pb
13	1010	950	pb

1. Với mỗi mô hình, tính $\hat{y}$, phần dư $e = y - \hat{y}$ và e^2 cho cả bốn cuốn.
2. Tính SSE_0 và SSE_1 trên riêng bốn quan sát này. So sánh kết quả và nhận xét.
3. Chỉ ra một cuốn sách mà thêm biến `cover` làm sai số bình phương của riêng quan sát đó lớn hơn. Vì sao điều này không mâu thuẫn với phương pháp bình phương tối thiểu khi M_1 được khớp trên toàn bộ dữ liệu?

Bài 4

Quay lại bốn nhà hàng ở Bài 2. Đặt

$$W_i = \begin{cases} 1, & \text{nhà hàng ở phía tây Manhattan (west),} \\ 0, & \text{nhà hàng ở phía đông Manhattan (east).} \end{cases}$$

Dữ liệu là:

Nhà hàng	food x	price y	W
Daniella Ristorante	22	43	1

Nhà hàng	food x	price y	W
Tello's Ristorante	20	32	1
Pasticcio	20	34	0
Belluno	22	39	0

Dùng mô hình hồi quy tuyến tính bội

$$\hat{y} = b_0 + b_1 x + b_2 W.$$

1. Từ ba điều kiện bình phương tối thiểu

   $$\sum e_i = 0, \qquad \sum x_i e_i = 0, \qquad \sum W_i e_i = 0,$$

   hãy tự lập hệ ba phương trình theo b_0, b_1, b_2.
2. Giải hệ để tìm b_0, b_1, b_2.
3. Tính bốn phần dư và SSE. So sánh với SSE của mô hình chỉ có `food` ở Bài 2.
4. Không cần tính toán dài: giải thích vì sao, khi cùng dùng một tập dữ liệu huấn luyện, thêm một biến giải thích vào mô hình bình phương tối thiểu không thể làm SSE tối thiểu tăng lên.

Bài 5

Vẫn dùng mô hình OpenIntro

$$\widehat{weight} = 197.96 + 0.72\, volume - 184.05 I(pb),$$

với bìa cứng (`hb`) là mức tham chiếu.

1. Định nghĩa $H = 1$ nếu `hb`, $H = 0$ nếu `pb`. Không thiết lập lại đường hồi quy, hãy biến đổi đại số để viết mô hình tương đương

   $$\widehat{weight} = a_0 + a_1\, volume + a_2 H.$$

   Tìm a_0, a_1, a_2.
2. Với một cuốn có `volume = 900`, tính dự đoán cân nặng nếu là `hb` và nếu là `pb` bằng cả hai cách mã hóa.
3. Đại lượng nào không đổi khi ta đổi mức tham chiếu: khoảng cách dự đoán giữa hai loại bìa, hệ số chặn, dấu của hệ số biến chỉ báo, hay cả ba? Giải thích.

Bài 6

Cho hai mô hình hồi quy với biến `flipper_length_mm`:

$$M_1: \quad \widehat{flipper} = 127.330 + 1.674\, bill_length,$$

và

$$M_2: \quad \widehat{flipper} = 147.563 + 1.096\, bill_length \\ - 5.247 I(Chinstrap) + 17.552 I(Gentoo),$$

với Adelie là mức tham chiếu.

1. Với `bill_length_mm = 43`, tính dự đoán của M_2 cho **Adelie, Chinstrap và Gentoo**.
2. Đổi mức tham chiếu sang Chinstrap. Không dùng phần mềm và không khớp lại dữ liệu, hãy viết toàn bộ phương trình mới của M_2.
3. Dùng phương trình mới để kiểm tra lại dự đoán cho một Gentoo có mỏ dài 43 mm.
4. M_1 có hệ số góc là 1.674, còn hệ số góc của `bill_length_mm` trong M_2 chỉ là 1.096. Điều này có mâu thuẫn gì không?

Bài 7

Trong toàn bộ dữ liệu Palmer Penguins, tương quan giữa `bill_length_mm` và `bill_depth_mm` xấp xỉ

$$r_{all} = -0.235.$$

Nhưng khi tính riêng theo loài, ta thu được xấp xỉ:

Species	r(bill length, bill depth)
Adelie	+0.391
Chinstrap	+0.654
Gentoo	+0.643

Không cần tính thêm hệ số tương quan. Hãy trả lời:

1. Bốn con số trên có thể đồng thời đúng không? Giải thích bằng hình học dùng biểu đồ phân tán và vị trí các cụm loài.
2. Một nhà sinh học hỏi: "Trong **cùng một loài**, cá thể có mỏ dài hơn có xu hướng có mỏ sâu hơn hay nông hơn?" Nên dùng r_{all} hay ba r theo loài? Vì sao?
3. Một nhà phân tích nói: "Vì $r_{all} < 0$, làm mỏ dài thêm sẽ làm mỏ nông đi." Hãy đánh giá xem phát biểu này có vấn đề hay không.

Bài 8

Với toàn bộ dữ liệu về `penguins`, STAT20 cho mô hình dự đoán chiều dài cánh bơi từ chiều dài mỏ

$$\widehat{flipper} = 127.330 + 1.674\, bill_length,$$

và tương quan giữa hai biến xấp xỉ $r = 0.656$.

Một sinh viên muốn dự đoán `bill_length` từ `flipper_length` nên giải ngược phương trình:

$$\widehat{bill_length} = \frac{flipper_length - 127.330}{1.674}.$$

1. Phương trình "giải ngược" này có phải tự động là đường bình phương tối thiểu để dự đoán `bill_length` từ `flipper_length` không?
2. Dùng công thức hệ số góc theo đơn vị gốc

$$b_{y|x} = r\frac{s_y}{s_x}, \qquad b_{x|y} = r\frac{s_x}{s_y},$$

   chứng minh rằng hệ số góc của đường thứ hai chỉ bằng nghịch đảo hệ số góc của đường thứ nhất trong một trường hợp đặc biệt. Nêu trường hợp đó.
3. Giải thích trực giác: tại sao "tối thiểu hóa khoảng cách thẳng đứng theo y" và "tối thiểu hóa khoảng cách thẳng đứng theo x" là hai bài toán khác nhau khi đám mây điểm không nằm hoàn toàn trên một đường thẳng?
4. Với $r = 0.656$, bạn kỳ vọng sai khác giữa hai đường là đáng kể hay gần như bằng 0? Giải thích.
